

Kapitel 1

Introduktion till Statistisk Analys

Introduktion till Statistisk Analys

- Kursintroduktion
 - Kurs-PM
 - Upplägg
 - Examination
- Datatyper
- Population och Stickprov
- Centraltendens
- Spridningsmått och kvartiler

Kurinstroduktion

- Upplägg
 - Föreläsningar
 - Python-demos (Notebooks)
 - Räkneövningar
- Examination
 - Inlämningsuppgift (Python)
 - Tenta (Beräkning för hand)
- Kurs-PM

Datatyper

Data kategoriseras på olika sätt:

- Nominal
- Ordinal
- Intervall
- Kvot
- Diskret
- Kontinuerlig

	Nominal	Ordinal	Interval	Ratio
Categorizes and labels variables	✓	✓	✓	✓
Ranks categories in order		✓	✓	✓
Has known, equal intervals			✓	✓
Has a true or meaningful zero				✓

Populationsdata

Populationsdata beskriver *alla* värden i en data mängd:

- Alla invånare i Sverige
- Alla anställda på ett visst företag
- Alla besökare till en restaurang

Populationsdata är mycket sällan tillgängligt för statistiker.

- Urvalet för stort, eller oändligt
- Urvalet är destruktivt

Stickprov

Ett stickprov (eng. sample), är en mindre mängd observationer av en population.

De flesta beräkningar och uppskattningar i den här kursen kommer utgå från stickprov.

Att genomföra stickprov på ett korrekt sätt kan vara en hel kurs i sig självt, och beror på många faktorer.

- Statistisk styrka
- Ekonomi
- Datahantering
- Databehandling
- Etik

Stickprov

Oberoende slumpmässigt urval (OSU) (eng. Simple Random Sample, SRS)

Ett OSU är ett urval från en population där alla datapunkter väljs slumpmässigt, med samma sannolikhet.

I praktiken inte alltid enkelt att genomföra, men en bra teoretisk utgångspunkt.

Centraltendens

Vad är "centrum" i en datamängd?

- Typvärde
 - Median
 - Medelvärde (aritmetiskt medelvärde)
-
- Geometriskt medelvärde
 - Harmoniskt medelvärde
 - Interkvartil medelvärde

Typvärde

Typvärdet (eng. Mode) är det värde som förekommer oftast i en datamängd

Exempel - Bilar på en parkeringsplats har följande färger:

{Röd; Svart; Svart; Vit; Blå; Vit; Svart; Röd}

Typvärdet för färg på bilar är:

Svart (3 ggr)

Median

Medianen är det värde som hamnar i mitten av datamängden då den ordnats i storleksordning

Exempel: {3, 6, 4, 8, 4, 1, 3}

Medianvärdet är:

{1, 3, 3, 4, 4, 6, 8}

Median

Medianen är det värde som hamnar i mitten av datamängden då den ordnats i storleksordning

Exempel: {3, 6, 4, 8, 4, 1, 3}

Medianvärdet är:

{1, 3, 3, 4, 4, 6, 8}

Median

Medianen är det värde som hamnar i mitten av datamängden då den ordnats i storleksordning

Om antalet datapunkter är jämnt, är medianen mitt mellan mittenvärdena.

$$\{3, 6, 4, 8, 4, 1, 3, 2\} \rightarrow \{1, 2, 3, 3, 4, 4, 6, 8\} \rightarrow 3 + 4 / 2 = 3.5$$

Medelvärde

Formellt, aritmetiskt medelvärde (eng. arithmetic mean)

Summan av alla värden, dividerat med antal värden:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + \dots + x_n}{n}$$

Exempel $\{3, 6, 4, 8, 4, 1, 3\} \rightarrow \mu = \frac{3+6+4+8+4+1+3}{7} \approx 4.14$

Om medelvärdet är för ett stickprov betecknas det istället med \bar{x} .

Spridningsmått

- Varians
- Standardavvikelse
- Kvartilavstånd
- Medelabsolutavvikelse

Varians

Den normerade kvadrerade avvikelser från medelvärdet:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

För ett stickprov:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

Skillnaden i nämnaren är relaterat till antalet *frihetsgrader* (eng. *degrees of freedom*)

Varians

Antalet frihetsgrader avgörs av hur många okända parametrar vi tar med oss in i beräkningen.

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Eftersom medelvärdet μ är beräknat utifrån stickprovet korrigerar vi för detta genom att sätta antalet frihetsgrader till $n - 1$ istället för n .

Varians

En mindre beräkningsintensiv form för stickprovsvarians:

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - n\bar{x}^2}{n - 1}$$

Standardavvikelse

Standardavvikelse (eng. standard deviation) är kvadratroten av variansen.

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Standardavvikelse är mer lättbegripligt. Jämför enheterna för varians och standardavvikelse

Kvartilavstånd

Kvartiler är som medianer, fast uppdelat i fyra. Den andra kvartilen *är* medianen.



Kvartilavstånd

Den första kvartilen är medianen av datamängden till vänster om medianen.



Kvartilavstånd

Den tredje kvartilen är medianen av datamängden till höger om medianen.



Kvartilavstånd

Kvartilavståndet (eng. Interquartile range, IQR) är avståndet mellan den första och tredje kvartilen.



Medelabsolutavvikelse

Medelabsolutavvikelse (eng. Mean Absolute Deviation – MAD) är medelvärdet av *absolutavvikelser* från medelvärdet.

$$MAD = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

MAD är mer *robust* än standardavvikelse, och används ibland inom utveckling av prediktionsmodeller.